Universidad Autonoma de Occidente

Fundamentos y Aplicaciones de Inteligencia Artificial

MiniProyecto 2 - Clasificacion de niveles de obesidad

Informe final

Profesor: Juan Sebastian Mosquera Maturana

Fecha: 17/04/2026

Integrantes

Valentina Popo Montilla

Juan Camilo Balleresteros Sierra

Santigo Rodriguez Gacha

MiniProyecto 2 - Problema de Clasificacion

Integrantes

• Valentina Popo Montilla

• Juan Camilo Balleresteros Sierra

• Santigo Rodriguez Gacha

1. Descripcion del dataset

Se utilizo el dataset **Estimation of Obesity Levels Based On Eating Habits and Physical Condition** del repositorio UCI. El conjunto contiene informacion de habitos de alimentacion, condicion fisica y caracteristicas antropometricas para clasificar el nivel de obesidad de una persona.

• Registros originales: **2111**

• Variables originales: **17**

• Variables numericas: **8**

• Variables categoricas: **8** predictoras + la variable objetivo

• Variable objetivo: **NObeyesdad**

• Clases objetivo: **7**

• Valores faltantes detectados: **0**

• Filas duplicadas exactas detectadas: **24**

Distribucion de clases:

Clase	Frecuencia
Insufficient_Weight	272
Normal_Weight	287
Obesity_Type_I	351
Obesity_Type_II	297
Obesity_Type_III	324
Overweight_Level_I	290
Overweight_Level_II	290

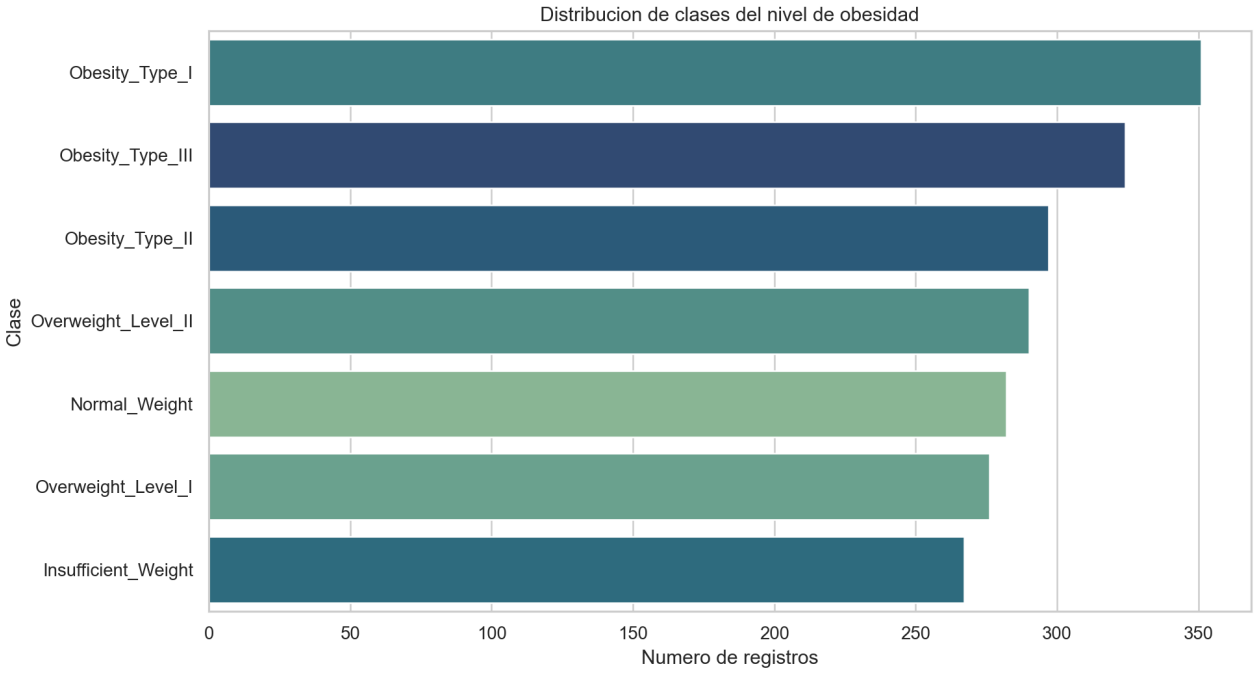

Distribucion de clases

2. Analisis exploratorio y depuracion de variables

Se aplico un proceso de depuracion con las siguientes reglas:

1. Eliminar columnas con mas del 50% de valores faltantes.

2. Eliminar columnas con varianza cero.

3. Revisar correlaciones numericas absolutas mayores a 0.85 para evitar redundancia.

4. Eliminar filas duplicadas exactas.

Resultados de la depuracion:

• Columnas con mas del 50% de faltantes: **0**

• Columnas con varianza cero: **0**

• Pares numericos con correlacion mayor a 0.85: **0**

• Columnas eliminadas por depuracion: **Ninguna**

• Filas duplicadas eliminadas: **24**

• Registros finales para modelado: **2087**

En este dataset no fue necesario eliminar variables por faltantes, varianza cero o alta correlacion. La limpieza se concentro en retirar los duplicados exactos, quedando un conjunto final de **2087** registros.

La matriz de correlacion de las variables numericas se presenta a continuacion:

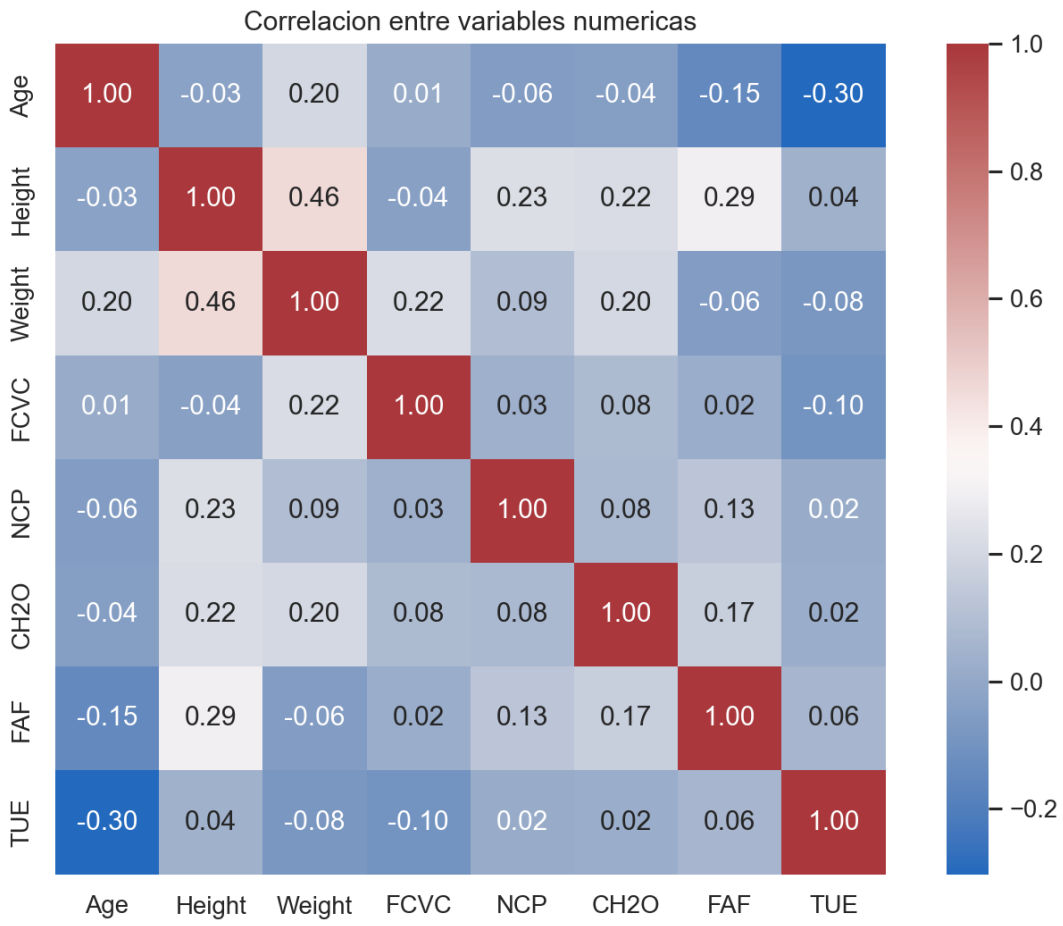

Correlacion numerica

Como variable ilustrativa, el peso muestra una separacion clara entre varias clases objetivo:

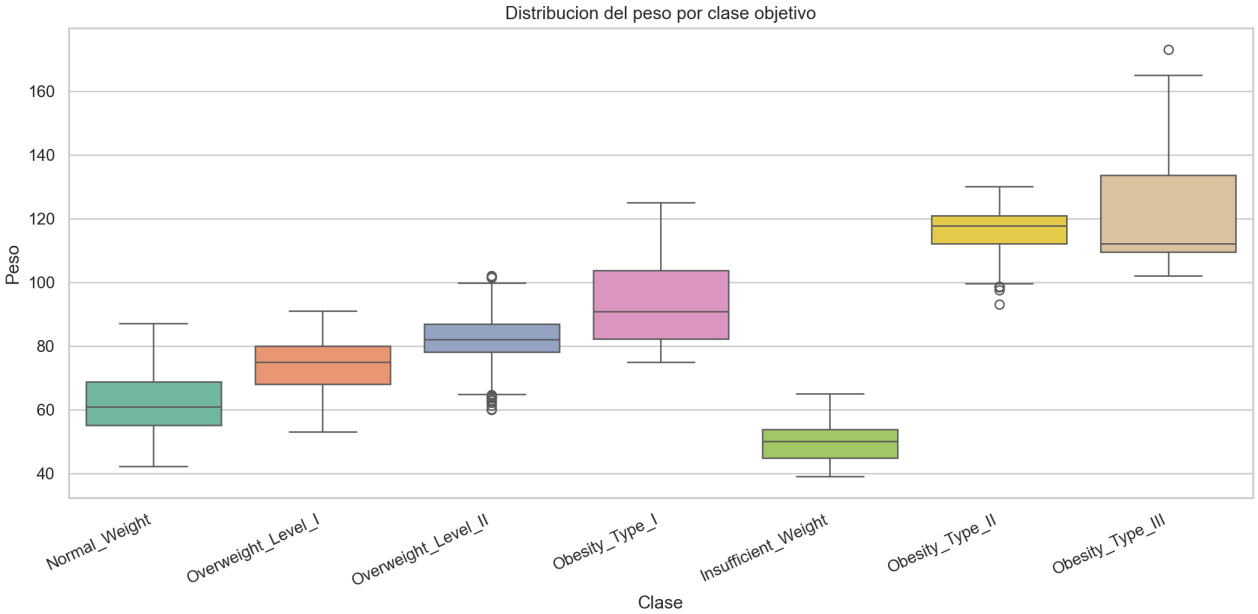

Peso por clase

3. Division del dataset y metodologia

Para entrenar y validar los modelos se realizo una particion estratificada:

• Entrenamiento: **1669** registros

• Prueba: **418** registros

• Proporcion de prueba: **20%**

• Semilla aleatoria: **42**

Las variables numericas fueron imputadas con la mediana y estandarizadas. Las variables categoricas fueron imputadas con la moda y codificadas mediante **One-Hot Encoding**. El ajuste de hiperparametros se realizo con **GridSearchCV** de 5 particiones, optimizando la metrica **F1 macro**.

4. Modelos de clasificacion evaluados

Se entrenaron cuatro modelos:

1. **Regresion Logistica** - modelo lineal multiclase visto en clase.

2. **SVM con kernel RBF** - modelo visto en clase.

3. **Arbol de Decision** - modelo visto en clase.

4. **Random Forest** - modelo adicional no visto en clase. Este metodo combina multiples arboles de decision y toma la clase final por votacion, lo que suele mejorar la estabilidad frente a un arbol individual.

5. Comparacion de resultados

Ademas de la matriz de confusion, se utilizo como indice adicional el **Matthews Correlation Coefficient (MCC)**, una metrica robusta para problemas multiclase porque resume la calidad global de la clasificacion considerando verdaderos y falsos positivos y negativos.

label	course_type	cv_f1_macro	test_accuracy	test_balanced_accuracy	test_f1_macro	test_mcc
SVM con kernel RBF	Visto en clase	0.9546	0.9713	0.9704	0.9697	0.9665
Arbol de Decision	Visto en clase	0.9318	0.9593	0.9586	0.9583	0.9526
Random Forest	No visto en clase	0.9334	0.9402	0.9379	0.9389	0.9307
Regresion Logistica	Visto en clase	0.9352	0.9402	0.9392	0.9383	0.9303

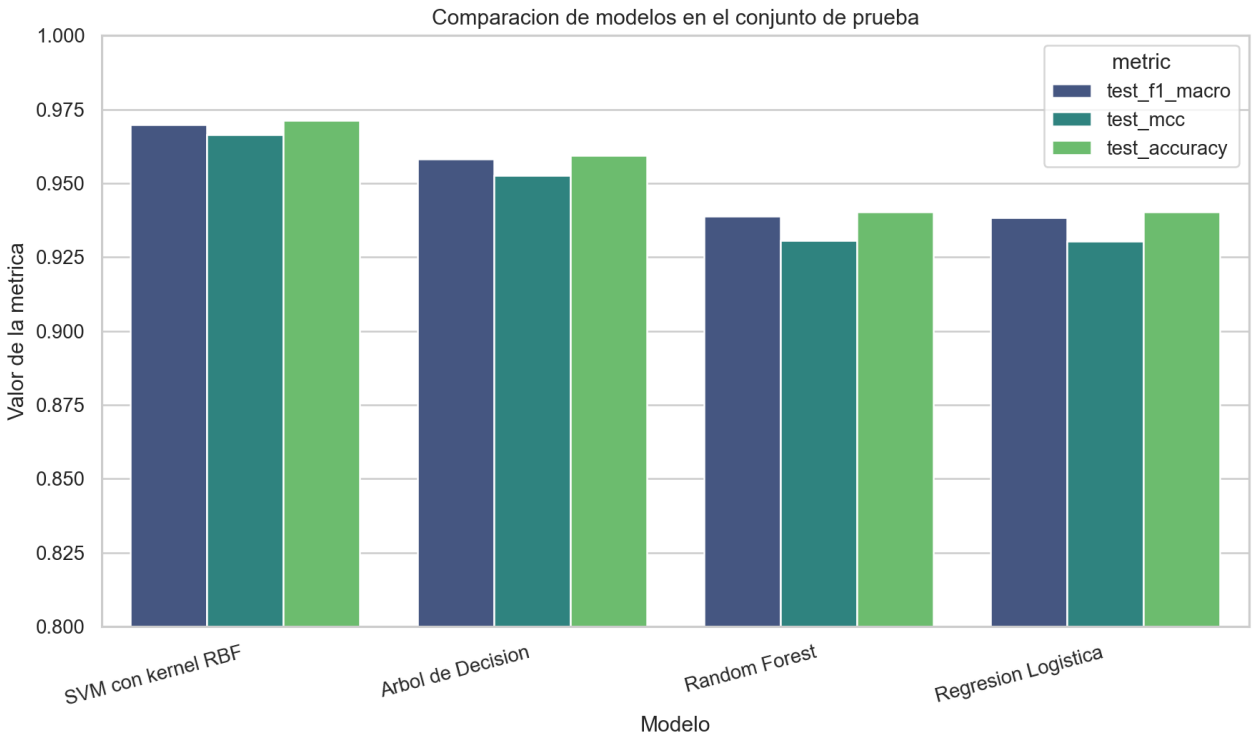

Comparacion de modelos

Matrices de confusion generadas:

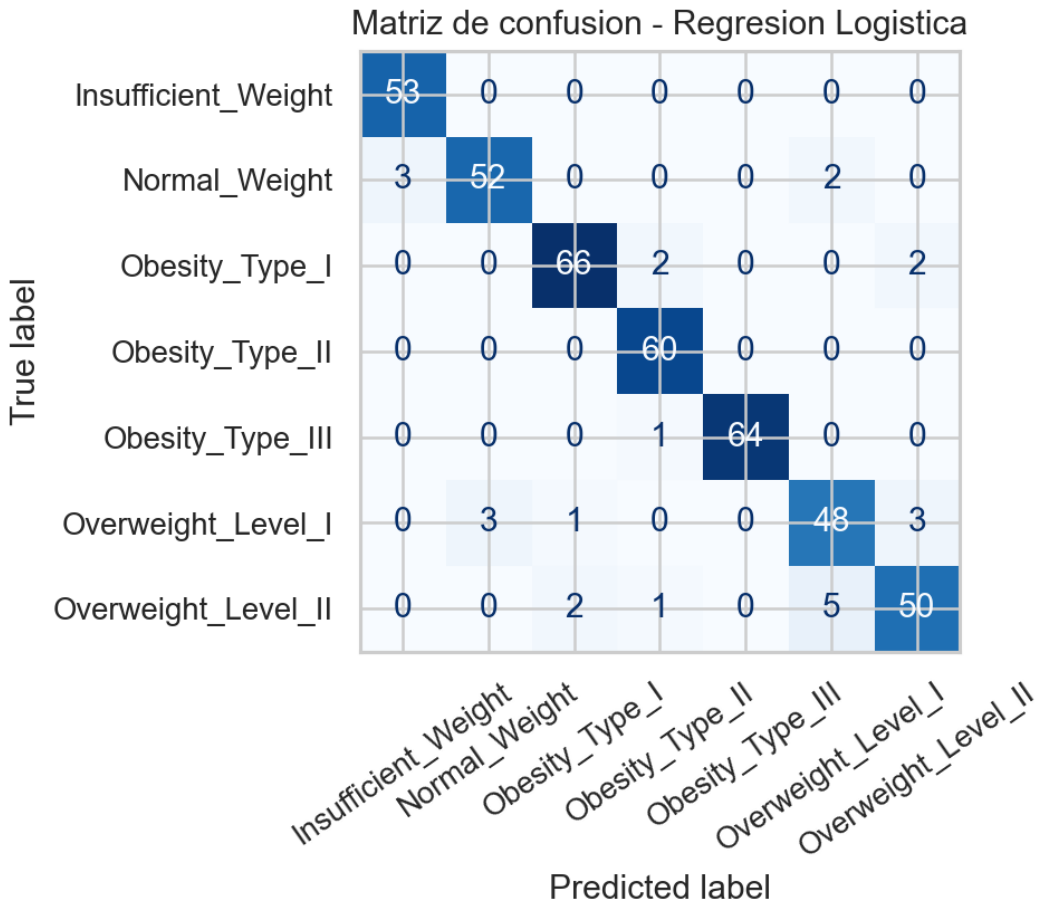

Matriz Regresion Logistica

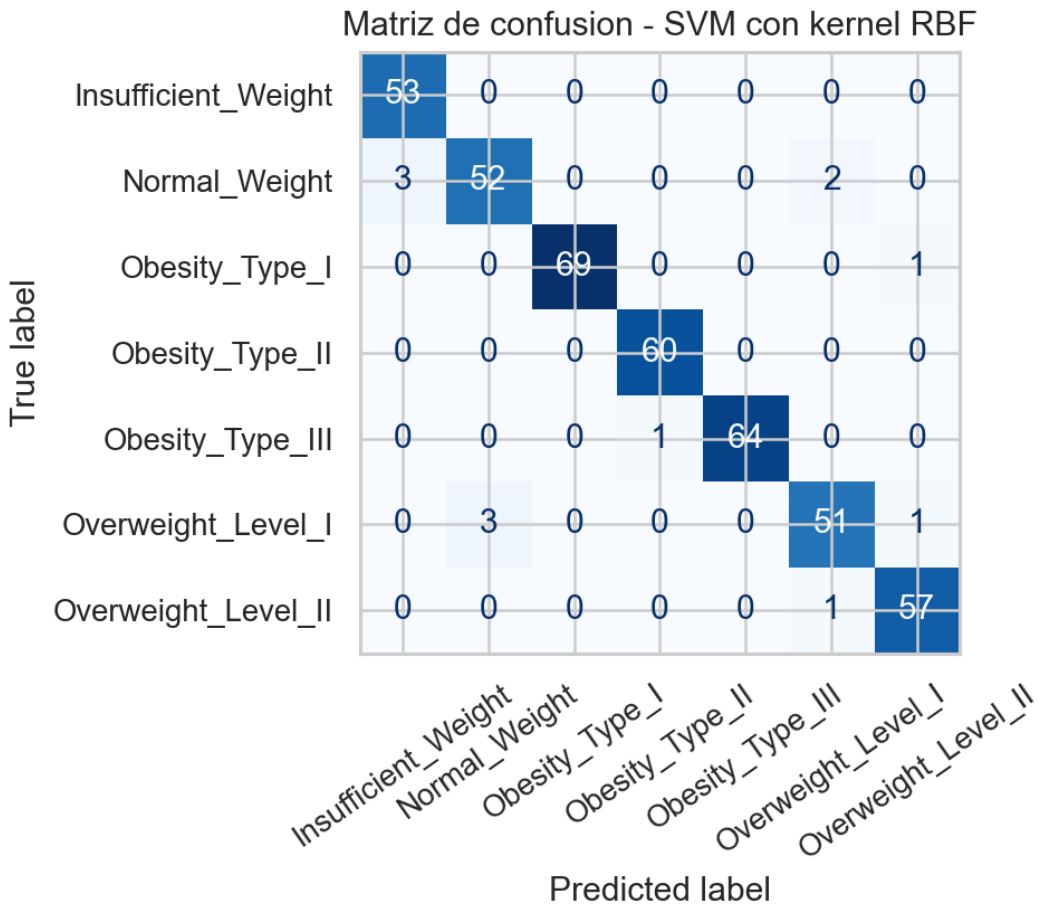

Matriz SVM

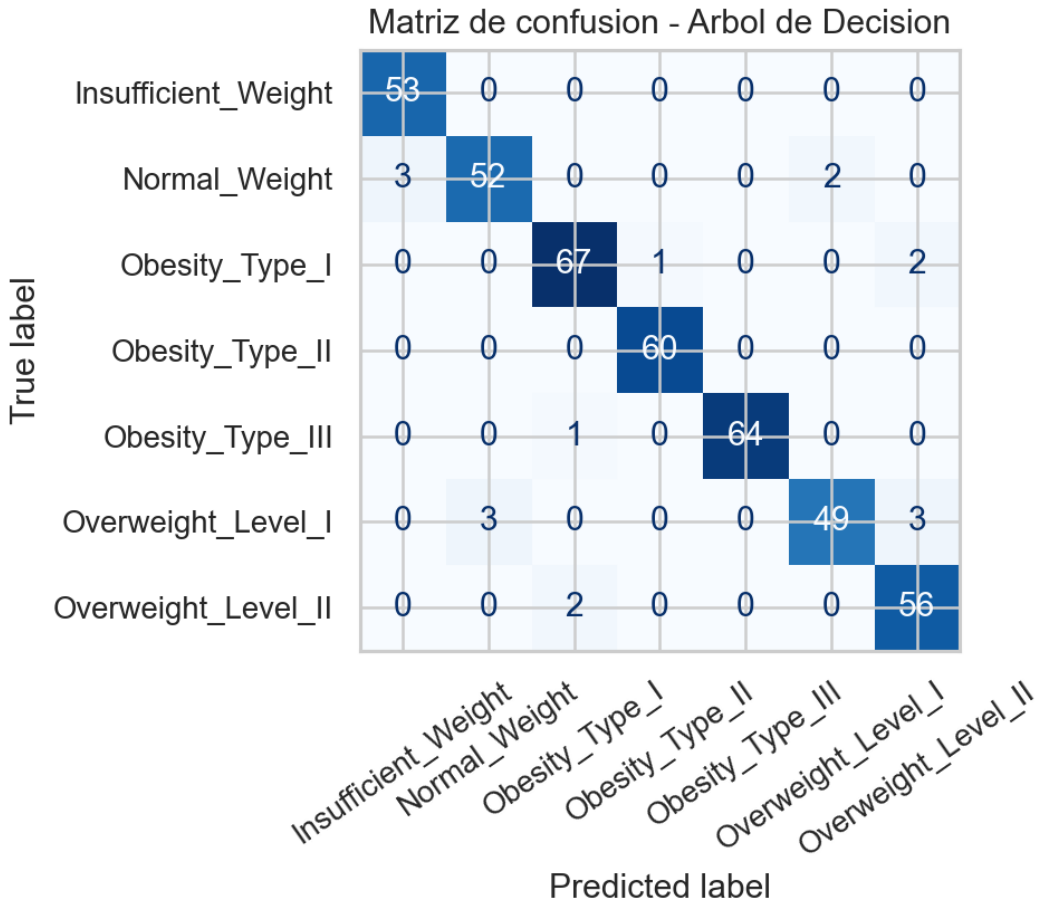

Matriz Arbol de Decision

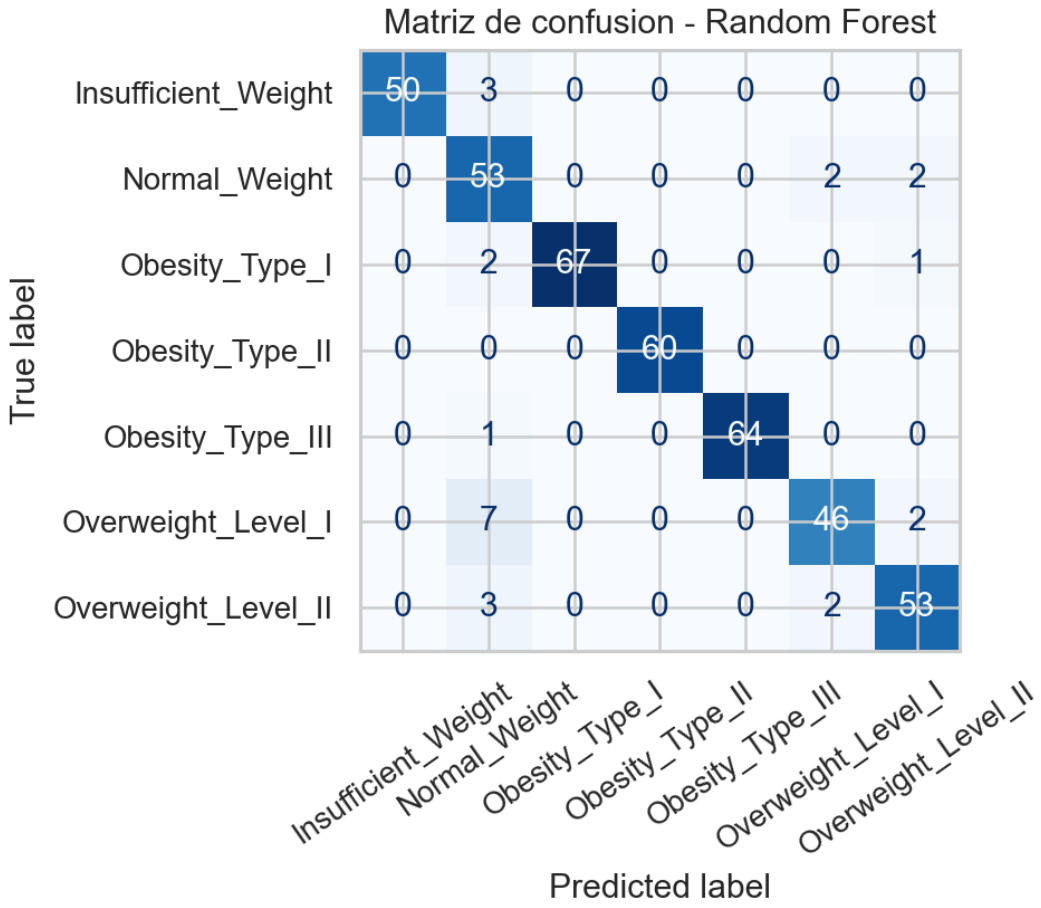

Matriz Random Forest

6. Mejor modelo e hiperparametros

El mejor modelo del experimento fue **SVM con kernel RBF**, ya que obtuvo los mejores valores en el conjunto de prueba tanto para **F1 macro** (**0.9697**) como para **MCC** (**0.9665**).

Hiperparametros optimos encontrados:

```
{
"model__C": 10,
"model__gamma": 0.03,
"model__kernel": "rbf"
}
```

Las variables con mayor influencia estimadas mediante importancia por permutacion fueron:

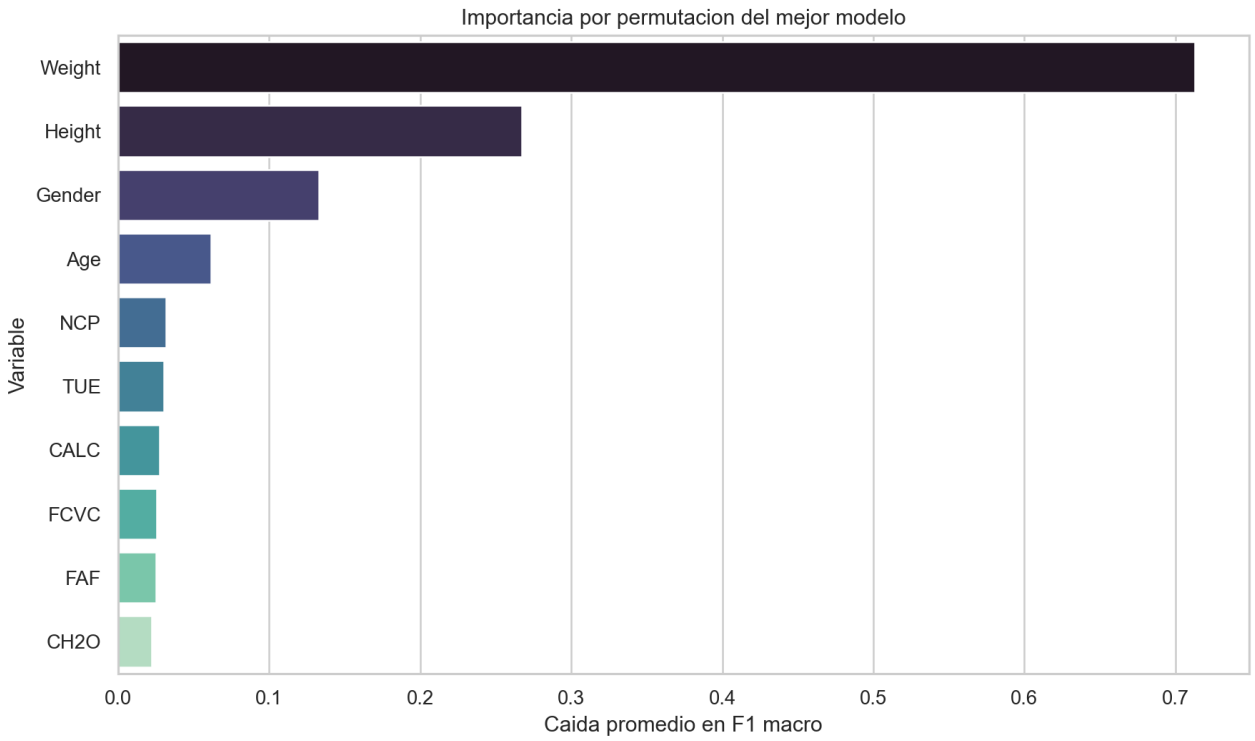

Importancia del mejor modelo

7. Conclusiones

1. El dataset presenta una estructura relativamente limpia: no tiene valores faltantes y tampoco muestra columnas con varianza cero ni correlaciones numericas extremas. La principal accion de depuracion fue eliminar **24** registros duplicados.

2. Los cuatro modelos alcanzaron desempenos altos, lo que sugiere que las variables del dataset contienen informacion suficiente para distinguir las clases objetivo.

3. **SVM con kernel RBF** fue el modelo mas solido al generalizar, con mejor **F1 macro** y mejor **MCC** en el conjunto de prueba. Esto indica una mejor capacidad para separar fronteras no lineales entre los distintos niveles de obesidad.

4. Aunque el **Arbol de Decision** obtuvo un resultado competitivo, fue ligeramente inferior al SVM en las metricas globales, por lo que no seria la primera opcion para esta aplicacion.

5. **Random Forest**, como metodo adicional no visto en clase, mostro un rendimiento estable, pero en esta base no supero al SVM. Su principal ventaja sigue siendo la interpretabilidad agregada y la robustez frente a variaciones en los datos.

6. Para esta aplicacion concreta, el modelo recomendado es **SVM con kernel RBF**, porque ofrece el mejor equilibrio entre precision global, sensibilidad promedio por clase y correlacion global de las predicciones.

7. Como limitacion metodologica, el propio UCI reporta que cerca del 77% de los datos fue generado sinteticamente con SMOTE. Por eso, aunque el desempeno es alto, los resultados deben interpretarse con cautela al extrapolarlos a poblaciones reales.

8. Archivos generados

- Script principal: `src/run_analysis.py`
- Notebook: `notebooks/miniproyecto_2_clasificacion_obesidad.ipynb`
- Resultados tabulares: `reports/results/`
- Figuras: `reports/figures/`