

MiniProyecto 3 - Garbage Classification

BORRADOR: pendiente ejecutar corrida full y actualizar resultados finales antes de entregar.

MiniProyecto 3 - Redes Neuronales Artificiales

Garbage Classification

Integrantes

- ? Valentina Popo Montilla
- ? Santiago Rodriguez Gacha
- ? Juan Camilo Ballesteros

1. Descripcion del problema

El objetivo del miniproyecto es resolver una tarea de clasificacion de imagenes usando redes neuronales artificiales. El dataset asignado es ****Garbage Classification****, disponible en Kaggle, y se trabaja con todas sus categorias.

La tarea consiste en clasificar imagenes de residuos en clases como carton, plastico, papel, metal, vidrio, basura, ropa, zapatos, residuos biologicos y baterias, entre otras. Este tipo de problema es relevante para aplicaciones de reciclaje automatizado, separacion de residuos y sistemas de vision artificial aplicados al medio ambiente.

2. Dataset

Fuente: <https://www.kaggle.com/mostafaabla/garbage-classification>

Categorias esperadas del dataset:

- ? battery
- ? biological
- ? brown-glass
- ? cardboard
- ? clothes
- ? green-glass
- ? metal

- ? paper
- ? plastic
- ? shoes
- ? trash
- ? white-glass

El notebook inspecciona automaticamente las carpetas descargadas desde Kaggle y usa todas las categorias disponibles.

3. Division de datos

El dataset se divide en tres subconjuntos:

- ? Entrenamiento: 70%
- ? Validacion: 15%
- ? Prueba: 15%

La particion se realiza de forma estratificada por carpeta de clase para mantener representacion de todas las categorias.

4. Preprocesamiento

Las imagenes se redimensionan a 128 x 128 pixeles. Se normalizan los valores de pixeles al rango [0, 1] y se aplica data augmentation en los modelos CNN y transfer learning mediante rotaciones, zoom y volteo horizontal.

5. Arquitecturas implementadas

5.1 MLP

La primera arquitectura usa una red densa multicapa. Las imagenes se aplanan y pasan por capas densas con regularizacion `Dropout`. Este modelo sirve como linea base, aunque no aprovecha la estructura espacial de las imagenes.

5.2 CNN original

La segunda arquitectura es una red convolucional propia con bloques `Conv2D`, `MaxPooling2D`, `BatchNormalization` y `Dropout`. Esta arquitectura aprende filtros espaciales directamente sobre las imagenes.

5.3 Transfer learning

La tercera arquitectura usa **MobileNetV2** preentrenada en ImageNet como extractor de características. Sobre esta base se agrega una cabeza de clasificación adaptada al número de categorías del dataset.

6. Evaluación

Para cada arquitectura se calculan:

- ? Matriz de confusión.
- ? Classification Report.
- ? ROC-AUC curve por clase.
- ? Accuracy y macro F1 en el conjunto de prueba.

Los resultados se exportan automáticamente en `/content/garbage_outputs`` al ejecutar el notebook.

7. Observaciones esperadas

Se espera que la MLP tenga el rendimiento más bajo porque no explota patrones espaciales. La CNN debería mejorar al aprender filtros visuales específicos del dataset. El modelo de transfer learning debería alcanzar el mejor desempeño general porque reutiliza representaciones visuales aprendidas en un conjunto de imágenes mucho más grande.

8. Conclusiones

El enfoque recomendado para esta aplicación es usar transfer learning con MobileNetV2, especialmente si el dataset no es muy grande o si las clases presentan variaciones visuales importantes. La CNN original es una alternativa válida para comparar aprendizaje desde cero, mientras que la MLP funciona como línea base pedagógica.

La entrega principal es el notebook de Colab, que contiene la descarga del dataset, preparación de datos, entrenamiento de las tres arquitecturas y evaluación completa.