

Universidad Autonoma de Occidente

Facultad de Ingenieria

Fundamentos y Aplicaciones de Inteligencia Artificial

Tarea 2 FIA

Clasificacion multi-label de generos de peliculas usando posters

Tipo de tarea	Clasificacion multi-label con CNN
Dataset	Movies-Poster_Dataset
Entorno final	Google Colab - GPU T4
Fecha	21/05/2026

Profesor: Juan Sebastian Mosquera Maturana

Integrantes

Valentina Popo Montilla

Juan Camilo Balleresteros Sierra

Santiago Rodriguez Gacha

Resumen ejecutivo

Se implemento una red neuronal convolucional original para clasificar generos de peliculas a partir de posters. El problema se formulo como clasificacion multi-label, usando activacion sigmoid y perdida binary_crossentropy, porque una misma pelicula puede pertenecer simultaneamente a varios generos.

0.6830 val_auc	0.8895 val_binary_accuracy	0.2919 val_loss	10 epocas
--------------------------	--------------------------------------	---------------------------	---------------------

Datos y procesamiento

El notebook clona el dataset desde GitHub, lee el CSV principal, asocia cada registro con su imagen por medio del identificador Id/IMDB y transforma los generos en etiquetas binarias. La lectura de imagenes se realiza con ImageDataGenerator.flow_from_dataframe, cumpliendo la recomendacion del enunciado.

Paso	Descripcion
1	Clonacion del repositorio Movies-Poster_Dataset.
2	Lectura del CSV y deteccion de columnas Id y Genre.
3	Cruce entre Id de pelicula y archivo de imagen.
4	Conversion de generos a etiquetas multi-label con MultiLabelBinarizer.
5	Division en entrenamiento, validacion y prueba.
6	Aumento de datos y normalizacion con ImageDataGenerator.

Modelo propuesto

La CNN usa bloques Conv2D, BatchNormalization y MaxPooling2D para extraer patrones visuales, seguidos por GlobalAveragePooling2D, Dropout y capas densas. La capa final tiene una neurona por genero y activacion sigmoid. Este diseno mantiene la arquitectura simple, original y adecuada para la sustentacion.

Componente	Funcion
Conv2D	Extrae bordes, texturas, formas y composicion visual del poster.
BatchNormalization	Estabiliza el entrenamiento.
MaxPooling2D	Reduce resolucion espacial y costo computacional.
Dropout	Reduce sobreajuste.
Sigmoid	Permite activar varios generos al mismo tiempo.
Binary crossentropy	Evalua cada etiqueta como una decision binaria independiente.

Resultados finales

La ejecucion final se realizo en Google Colab con GPU T4 durante 10 epocas. La mejor metrica de validacion se obtuvo al cierre del entrenamiento, con val_auc de 0.6830 y val_loss de 0.2919.

Metrica	Valor
binary_accuracy entrenamiento	0.8921
auc entrenamiento	0.6819
loss entrenamiento	0.2883
val_binary_accuracy	0.8895
val_auc	0.6830
val_loss	0.2919
ROC-AUC promedio por genero	0.6756
ROC-AUC mediano por genero	0.6810
F1 micro	0.4288
F1 ponderado	0.2965
F1 por muestras	0.4252




Figura 1. Curvas de accuracy y loss.

ROC-AUC por genero

El ROC-AUC por genero muestra mejor separacion en categorias visualmente mas distinguibles y con patrones recurrentes en los posters. Los generos minoritarios o mas ambiguos presentan menor rendimiento.

Genero	ROC-AUC
Animation	0.8441
Comedy	0.7941
Horror	0.7689
Family	0.7648
Sci-Fi	0.7516
Mystery	0.7373
Thriller	0.7200
Fantasy	0.7087

Genero	ROC-AUC
Crime	0.6191
Sport	0.5961
History	0.5758
Biography	0.5663
War	0.5304
Music	0.5091




Figura 2. Curvas ROC por genero.

Interpretacion

La `binary_accuracy` es alta porque en una tarea multi-label existen muchas etiquetas negativas por cada imagen. Por esta razon, la interpretacion debe apoyarse tambien en el ROC-AUC por genero y en la prueba top 5 de una caratula externa. El classification report evidencia que el umbral fijo de 0.35 favorece generos frecuentes como Drama y Comedy, mientras que generos con menos muestras tienen menor recall.

Hallazgo	Lectura
Buen desempeno global	val_auc de 0.6830 y ROC-AUC promedio de 0.6756.
Generos destacados	Animation, Comedy, Horror, Family y Sci-Fi superan 0.75 de ROC-AUC.
Limitacion principal	Desbalance de clases y bajo recall en generos minoritarios.
Mejora futura	Ajustar umbrales por genero, aplicar balanceo o entrenar mas tiempo.

Prueba con caratula externa

El notebook incluye una celda para subir una imagen externa con `files.upload()`, redimensionarla al tamaño usado por la red, normalizarla y mostrar los cinco generos con mayor probabilidad. Esta prueba es la parte practica que permite contrastar la prediccion del modelo con los generos reales consultados en IMDB.

Conclusiones

La solucion cumple el objetivo del enunciado: implementa lectura de imagenes desde dataframe, una CNN original, evaluacion multi-label y prueba de una caratula externa. Los resultados son razonables para una CNN entrenada desde cero sobre un dataset desbalanceado. Para la sustentacion, conviene resaltar la diferencia entre clasificacion multiclase y multi-label, el uso de sigmoid y `binary_crossentropy`, y la interpretacion cuidadosa de `binary_accuracy` frente a ROC-AUC.