

Tarea 2 FIA - Movie Posters

BORRADOR: pendiente ejecutar corrida full y actualizar resultados finales antes de entregar.

Tarea 2 FIA - Clasificacion Multi-label de Generos de Peliculas

1. Objetivo

Implementar una red neuronal convolucional original para clasificar generos de peliculas a partir de sus caratulas. La tarea es **multi-label**, porque una misma pelicula puede pertenecer a varios generos al mismo tiempo.

2. Dataset

Dataset usado: https://github.com/laxmimerit/Movies-Poster_Dataset.git

El dataset contiene caratulas de peliculas y un archivo CSV con metadatos, entre ellos el campo de genero. Los generos se procesan como etiquetas multiples separadas por delimitadores como `|`.

3. Procesamiento

El notebook realiza los siguientes pasos:

1. Clona el repositorio del dataset.
2. Ubica automaticamente el CSV y la carpeta de imagenes.
3. Relaciona cada pelicula con su archivo de imagen.
4. Convierte la columna de generos a variables binarias mediante `MultiLabelBinarizer`.
5. Filtra generos con muy pocas muestras para mejorar estabilidad del entrenamiento.
6. Divide el dataset en entrenamiento, validacion y prueba.
7. Usa `ImageDataGenerator.flow\_from\_dataframe`, como solicita la guia de la tarea.

4. Modelo CNN propuesto

La arquitectura implementada es una CNN original con:

? Capas convolucionales `Conv2D`.

- ? Normalizacion por lotes ``BatchNormalization``.
- ? Reduccion espacial con ``MaxPooling2D``.
- ? Regularizacion ``Dropout``.
- ? Capa final ``Dense`` con activacion ``sigmoid``.

La activacion final es ``sigmoid`` porque se trata de clasificacion multi-label. La perdida usada es ``binary_crossentropy``.

5. Evaluacion

Se generan:

- ? Classification report por genero.
- ? ROC-AUC por genero.
- ? Grafica de entrenamiento y validacion.
- ? Funcion para subir una caratula nueva y mostrar los primeros 5 generos predichos.

6. Sustentacion breve

Para la sustentacion de maximo 5 minutos se recomienda explicar:

1. La diferencia entre clasificacion multiclase y multi-label.
2. Por que se usa ``sigmoid`` y ``binary_crossentropy``.
3. Como ``ImageDataGenerator.flow_from_dataframe`` permite leer imagenes y etiquetas desde un dataframe.
4. La arquitectura CNN propuesta.
5. La prueba con una caratula externa y los top 5 generos predichos.

7. Conclusiones

El enfoque permite resolver una tarea multi-label realista, donde cada poster puede activar varias etiquetas. La CNN aprende patrones visuales presentes en los posters, como paletas de color, rostros, composicion y elementos graficos asociados a generos cinematograficos.

El rendimiento final debe revisarse en el notebook luego de ejecutar el entrenamiento en Colab, especialmente las metricas ROC-AUC y el comportamiento de la prediccion sobre imagenes externas.